Adaptación y replicación de “Adversarial Sequence Mutations in AlphaFold and ESMFold Reveal Nonphysical Structural Invariance, Confidence Failures, and Concerns for Protein Design”

Moisés Isaí Barrientos Castillo
Víctor Alfredo León Medina

Resumen

Este trabajo presenta una adaptación y replicación del estudio de Feldman et al. sobre la robustez estructural de AlphaFold y ESMFold frente a mutaciones y deleciones adversariales en secuencias proteicas. Con el fin de reducir el costo computacional sin perder capacidad de análisis, se diseñó una metodología simplificada basada en proteínas monoméricas clasificadas como “similar” o “novel”, a partir de las cuales se generaron variantes con distintos porcentajes de mutación y deleción. Las estructuras predichas se compararon mediante TM-score y niveles de confianza pLDDT, y adicionalmente se exploró la relación entre la robustez observada y la disponibilidad de plantillas estructurales mediante Foldseek. Los resultados muestran que AlphaFold tiende a conservar una alta confianza incluso cuando la similitud estructural disminuye de forma importante, mientras que ESMFold presenta, en general, una mayor sensibilidad a las mutaciones. Asimismo, las proteínas con homologías previas en bases de datos históricas tienden a presentar mayor estabilidad estructural predicha, lo que sugiere una posible dependencia de información aprendida durante el entrenamiento. En conjunto, los hallazgos refuerzan la necesidad de evaluar críticamente el uso de estos modelos en tareas de diseño de proteínas y en contextos donde las secuencias han sido modificadas de manera sustancial.

Adaptación y replicación de "Adversarial Sequence Mutations in AlphaFold and ESMFold Reveal Nonphysical Structural Invariance, Confidence Failures, and Concerns for Protein Design"

1. Introducción y definición del problema

Se afirma ampliamente que AlphaFold [1] ha revolucionado la predicción de la estructura 3D de las proteínas a partir de su secuencia [2]. Uno de los elementos más importantes en la investigación biológica celular, molecular y biomédica son las proteínas y su estructura tridimensional, que es la que define su función. Ya que los métodos experimentales para conocer estas estructuras son muy tardados y costosos (cristalografía de rayos x, resonancias magnéticas nucleares y crio-microscopía electrónica) ha habido un gran esfuerzo computacional para poder predecir las estructuras tridimensionales. La Evaluación Crítica de Técnicas para la Predicción de Estructuras de Proteínas (CASP por sus siglas en inglés) es un concurso bianual en el que se presentan y comparan los últimos esfuerzos computacionales en este campo. En su edición número 14 (2020), AlphaFold2, presentado por DeepMind, tuvo resultados sin precedentes, con un puntaje total de z-score de 244.0 contra 90.8 del segundo mejor modelo ese año, o 68.3 de su primer modelo presentado en la 14va edición de CASP dos años antes. [3]

Este acceso sin precedentes a una gran cantidad de modelos altamente precisos impactó varias áreas de las ciencias de la vida. En la figura 1, Varadi y Velankar (2022) muestran el porcentaje de citaciones a la base de datos de estructuras de proteínas obtenidas con AlphaFold en diferentes campos. Los mismos autores mencionan que, por ejemplo:

- Los proveedores de datos están aprovechando el acceso programático a AlphaFold integrándolo en sus infraestructuras.
- Los investigadores en bioinformática realizan análisis de alto rendimiento para descubrir patrones y características a una escala antes impensable.
- Los biólogos estructurales utilizan los modelos de AlphaFold para resolver estructuras mediante la combinación de datos experimentales y las coordenadas del modelo teórico.
- Investigadores y compañías farmacéuticas emplean técnicas de descubrimiento de fármacos basadas en la estructura utilizando estos modelos.
- Los modelos de AlphaFold también se han convertido en herramientas poderosas para la enseñanza y la comprensión de la biología estructural, lo que ha dado lugar a nuevos y valiosos materiales de capacitación.

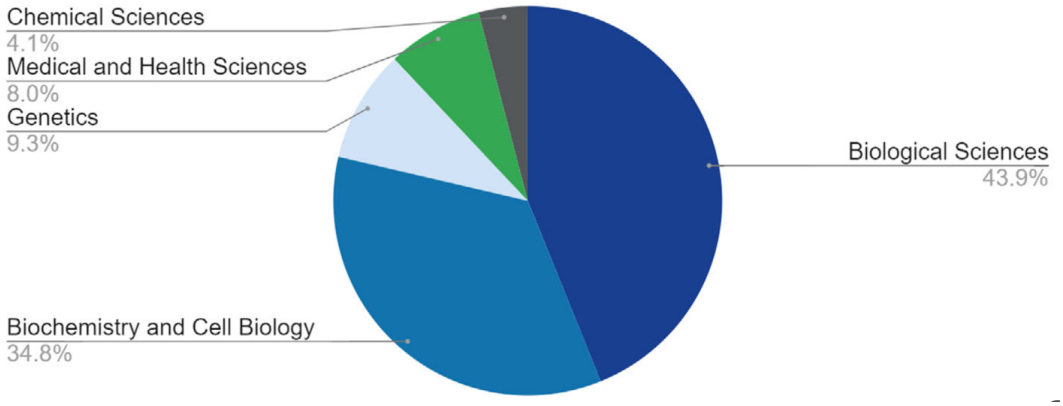

Figura 1: Áreas de las que se han citado estrcuturas predichas con AlphaFold. Tomada de [4].

Dado que hay tantas áreas y resultados impactados directa e indirectamente por las predicciones de AlphaFold, es relevante conocer sus limitaciones e identificar casos en los que puede no ser confiable. Por ejemplo, Pak et al. (2023) encontraron que AlphaFold no sirve para estimar de forma fiable el impacto de mutaciones en la estabilidad o función de una proteína, realizando un estudio de la correlación entre las métricas de confianza de proteínas mutadas y su estructura experimental real. Además, ya que parte del éxito predictivo de AlphaFold2 se debe a su uso de plantillas (estructuras ya conocidas de secuencias similares a la secuencia a predecir) [1] en el entrenamiento, es importante averiguar qué tanto dependen las predicciones de estas plantillas sobre las propiedades biofísicas de la secuencia de aminoácidos en cuestión.

Es aquí donde entra el trabajo de Feldman et al. (2026), quienes en su artículo "Adversarial Sequence Mutations in AlphaFold and ESMFold Reveal Nonphysical Structural Invariance, Confidence Failures, and Concerns for Protein Design" realizan una evaluación adversarial de AlphaFold 3 y ESMFold [8] para determinar si estos modelos comprenden principios biofísicos o si solo memorizan patrones. Los investigadores descubrieron que las predicciones de AlphaFold 3 permanecen invariantes incluso tras altas tasas de mutación o eliminación de residuos. Las métricas de confianza del sistema resultaron poco fiables, ya que parecen depender de la disponibilidad de plantillas previas más que de la calidad real del modelo. Al comparar los resultados con los de ESMFold, se demostró que este último tiene mayor sensibilidad a las mutaciones, sugiriendo un mejor aprendizaje de la relación secuencia-estructura, concluyendo que la excesiva dependencia de AlphaFold en datos memorizados puede limitar su aplicación en diseño de proteínas y descubrimiento de fármacos.

En este proyecto realizamos una versión adaptada de los experimentos presentados por Feldman et al. en su artículo para optimizar los recursos computacionales sin comprometer el análisis estadístico. A continuación, se presentan brevemente las arquitecturas y métricas de los modelos revisados; además, se explica la metodología del artículo original, la adaptación realizada por nosotros, los resultados obtenidos y su discusión.

1.1. Arquitectura y entrenamiento de AlphaFold 2

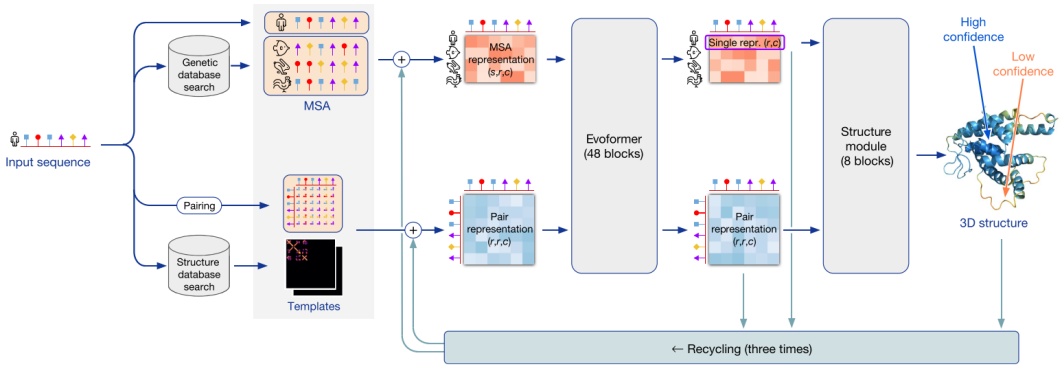

Figura 2: Esquema de la arquitectura y entrenamiento de AlphaFold 2.

AlphaFold 2 recibe como entrada la estructura primaria de una proteína, a partir de la cual construye un alineamiento múltiple de secuencias (MSA) con proteínas evolutivamente similares, y hace una búsqueda de estructuras tridimensionales conocidas para usar como plantilla. Su siguiente parte del pipeline es el "Evoformer", que son 48 bloques de transformer sin pesos compartidos, usando una representación de MSA y otra por par de aminoácidos. En cada bloque del Evoformer se aplica auto-atención por fila (una secuencia en todas sus posiciones) y columna (una posición en todas las secuencias), productos externos para transferir información del MSA a la representación de pares, y operaciones "triangulares" de tercias de nodos (operando a los aminoácidos como nodos y su interacción como aristas). Luego, el módulo de estructura usa atención equivariante en 3D para refinar iterativamente las posiciones y orientaciones de cada residuo hasta producir coordenadas atómicas. Todo el pipeline se repite 3 veces.

El entrenamiento es supervisado sobre estructuras del PDB, con dos ingredientes extra que mejoran la precisión: un objetivo tipo BERT que enmascara residuos del MSA para que la red aprenda covariaciones evolutivas, y self-distillation donde el modelo predice estructuras de secuencias sin etiqueta y se reentrena con esas predicciones como pseudo-etiquetas [1] [7].

1.2. Arquitectura y entrenamiento de ESMFold

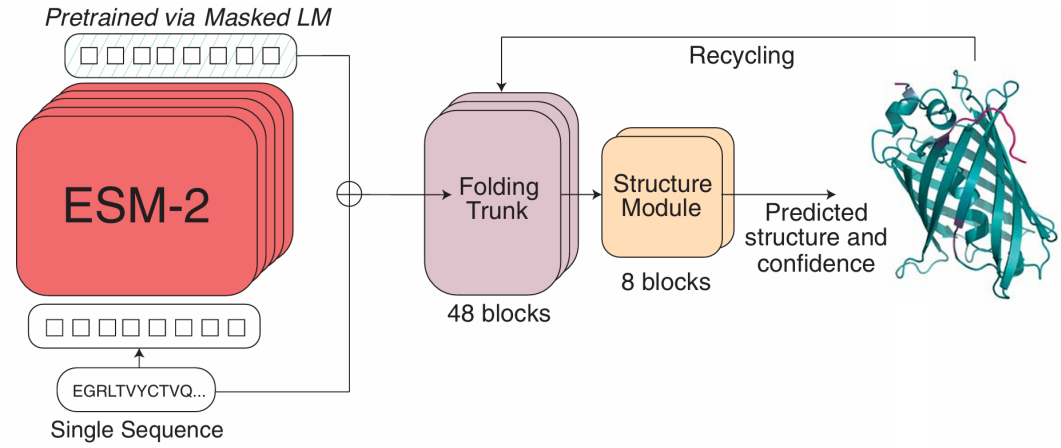

Figura 3: Esquema de la arquitectura y entrenamiento de ESMFold.

ESMFold surgió como una alternativa a AlphaFold, reemplazando el MSA por un modelo de lenguaje proteico preentrenado, ESM-2: un transformer BERT entrenado con masked language modeling sobre 250 millones de secuencias, que internaliza los patrones coevolutivos en sus pesos en lugar de computarlos explícitamente en inferencia. La secuencia pasa por ESM-2 (congelado) para obtener embeddings por residuo, que luego entran al "folding trunk" (que es como un Evoformer simplificado sin la maquinaria del MSA) para construir la representación de pares con producto externo y la refina. Esa representación alimenta el mismo módulo de estructura de AF2 para producir coordenadas 3D.

El entrenamiento ocurre en dos fases separadas: ESM-2 se preentrena autosupervisadamente solo sobre secuencias y luego se congela. Después se entrena el folding trunk y módulo de estructura de forma supervisada sobre estructuras del PDB, aumentadas con 12M predicciones de AlphaFold2 como pseudo-etiquetas. El resultado es un modelo 60 veces más rápido que AF2 porque elimina la búsqueda del MSA en inferencia, a costa de algo de precisión en proteínas difíciles donde el MSA explícito sigue siendo más informativo [8].

2. Métricas de evaluación

2.1. pLDDT

La prueba de diferencia de distancia local predicha (pLDDT) es una medida de confianza local por residuo. Se escala de 0 a 100, donde las puntuaciones más altas indican mayor confianza y, por lo general, una predicción más precisa. La pLDDT mide la confianza en la estructura local, estimando qué tan bien concordaría la predicción con una estructura experimental.

Con base en esto, una pLDDT superior a 90 se consideraría la categoría de mayor precisión, en la que tanto la cadena principal como las cadenas laterales se predicen típicamente con alta precisión.

Por el contrario, una pLDDT superior a 70 generalmente corresponde a una predicción correcta de la cadena principal con una ubicación incorrecta de algunas cadenas laterales [9].

2.2. TM-score

La similitud entre dos estructuras proteicas se puede medir mediante la puntuación TM (puntuación de modelado de plantilla). Esto resulta especialmente útil al examinar la calidad de un modelo, en comparación con una estructura objetivo o plantilla. Un método común para comparar estructuras proteicas consiste en calcular la desviación cuadrática media (RMSD) de las distancias entre residuos equivalentes en ambas estructuras. Un problema de este método es que, dado que todos los pares de residuos tienen el mismo peso, cuando el valor de RMSD es elevado, se vuelve más sensible a la desviación de la estructura local que a la topología global. Otras funciones de puntuación establecidas se basan en la búsqueda de subestructuras del modelo, donde todos los residuos se encuentran dentro de una distancia umbral determinada de los residuos de la plantilla correspondientes. Sin embargo, esta distancia umbral es subjetiva y, por lo tanto, no puede utilizarse como estándar para todas las proteínas. Una desventaja importante de todos estos métodos es que presentan una dependencia de ley de potencias con la longitud de la proteína.

La puntuación TM se desarrolló para superar esta dependencia de la longitud. Se trata de una variación de la puntuación de Levitt-Gerstein (LG), que pondera con mayor fuerza las distancias más cortas entre residuos correspondientes que las distancias más largas. Esto garantiza una mayor sensibilidad a la topología global que a las desviaciones de la estructura local.

El valor de la puntuación TM siempre se encuentra entre [0,1]; las evaluaciones de las distribuciones de la puntuación TM han demostrado que cuando la puntuación TM entre dos estructuras es $<0{,}17$, el valor p se aproxima a 1 y las estructuras proteicas son indistinguibles de pares de estructuras aleatorias. Cuando la puntuación TM alcanza 0,5, el valor p se reduce drásticamente y las estructuras se encuentran mayoritariamente en el mismo plegamiento. Por lo tanto, se sugiere que la puntuación TM puede ser útil no solo en la evaluación automatizada de predicciones de estructura proteica, sino también para determinar plegamientos similares en la clasificación de la topología proteica [10].

3. Metodología del artículo original

Los autores construyeron tres conjuntos de datos para evaluar el desempeño de AlphaFold 3. El principal contiene 200 proteínas divididas en cuatro categorías: monómeros novedosos, monómeros similares, multímeros novedosos y multímeros similares, con 50 ejemplos en cada grupo. Todas las proteínas fueron publicadas después del 30 de septiembre de 2021 para evitar solapamiento con el entrenamiento de AlphaFold 3. Además, incluyeron un conjunto específico de 15 proteínas con fold-switching, es decir, monómeros con múltiples conformaciones validadas experimentalmente, y un tercer conjunto de 100 proteínas (50 monómeros y 50 multímeros) tomado de los casos novedosos para comparar directamente el desempeño entre AlphaFold 2 y AlphaFold 3 bajo condiciones justas.

Para evaluar la robustez del modelo, se diseñó una estrategia de mutación adversarial orientada a maximizar el daño estructural. Se aplicaron mutaciones puntuales en distintos niveles (5 %, 10 %, 20 %, 40 % y 70 %), sustituyendo residuos hidrofóbicos pequeños por residuos polares grandes, con

un sesgo matemático que favorece mutaciones en el núcleo proteico. También se introdujeron mutaciones por deleción (1 %, 3 %, 5 % y 10 %), igualmente concentradas en regiones centrales. Estas perturbaciones fueron acumulativas, de modo que cada nivel incluye todas las modificaciones del nivel anterior, permitiendo evaluar degradaciones progresivas en la estructura.

En cuanto a la ejecución de los modelos, AlphaFold 3 se corrió con 10 ciclos de reciclaje y 5 muestras de difusión, excluyendo explícitamente el uso de plantillas estructurales para evitar sesgos por información externa. Para manejar deleciones, se ajustaron los alineamientos múltiples (MSAs) eliminando las columnas correspondientes, y se validó este procedimiento regenerando MSAs desde cero para descartar artefactos. Como referencia adicional, se utilizó ESMFold en el caso de monómeros, comparando su sensibilidad a mutaciones frente a AlphaFold 3.

Para investigar el origen de la confianza del modelo, se realizó un análisis estructural con FoldSeek sobre la base de datos PDB100. Se identificaron las mejores estructuras similares disponibles antes del corte temporal de entrenamiento y se cuantificó su calidad mediante el qtmscore, que mide la similitud estructural normalizada respecto a la proteína consulta. Esto permitió estimar hasta qué punto el modelo podría estar apoyándose en conocimiento previo implícito.

Finalmente, la evaluación se basó en métricas estructurales y análisis estadísticos. Se utilizó el TM-score para medir similitud global y DockQ para evaluar interfaces en complejos multiméricos. En los experimentos de mutación, las predicciones se compararon contra la estructura original sin mutaciones, mientras que en la comparación entre AlphaFold 2 y 3 se usaron estructuras experimentales como referencia. Para analizar relaciones entre variables, se emplearon correlaciones de Pearson y Spearman, examinando cómo el grado de mutación, la calidad de las plantillas y las métricas internas de confianza del modelo (como ranking score, pTM e ipTM) se interrelacionan.

4. Metodología adaptada

Debido a que el acceso gratuito a AlphaFold 3 es un limitado, decidimos realizar la metodología planteada por el artículo original pero para AlphaFold 2 que es de acceso totalmente libre para correr localmente o en el servidor de ColabFold. Creemos además, que el revelar las limitaciones de AlphaFold 2 también es relevante, pues por su misma accesibilidad es más usado que AlphaFold 3.

Debido a que AlphaFold suele tomar mucho tiempo de ejecución por su paso de Alineamiento Multiple de Secuencias optamos por tomar solo 60 proteínas, 30 de similares y 30 novels, con 3 niveles de mutacion y 3 niveles de deleción, dándonos 420 secuencias en total a correr, comparadas con las 2000 predichas en el artículo original. Nuestra hipotesis es que incluso con un menor número de proteínas, mutaciones y deleciones, se encontrarán las correlaciones encontradas por Feldman et al.

A continuación se explica con más detalle los pasos realizados en esta replicación adaptada.

4.1. Creación del dataset

Se utilizó la API de búsqueda del Protein Data Bank (PDB) para identificar proteínas monoméricas (que consisten en una sola cadena) cuya fecha de publicación inicial fuera posterior al 1 de enero de 2020, ya que la fecha “cutoff” de entrenamiento de AlphaFold fue en mayo de ese año. Este pull inicial constó de 142,821 proteínas.

De este grupo, se descargaron las secuencias y se aplicó un filtro de longitud para conservar únicamente aquellas de entre 50 y 300 aminoácidos, obteniendo un conjunto inicial de 2084 secuencias.

Se realizó una búsqueda de homología en la base de datos del PDB para clasificar las secuencias obtenidas. Cada secuencia se comparó contra las estructuras existentes publicadas antes del 1 de enero de 2020 utilizando un umbral de identidad de secuencia del 30 %. Las secuencias que obtuvieron coincidencias en la base de datos antigua ($\geq$ 30 % de identidad) se etiquetaron como "similar". Las secuencias que no arrojaron ninguna coincidencia bajo este criterio (<30 % de identidad) se catalogaron como "novel". También se aplicó un filtro de homología entre las secuencias de nuestro dataframe, pero al realizarlo llegaban a quedar incluso menos de 30 proteínas novelosas. Para evitar esto y asegurar un número suficiente de proteínas verdaderamente únicas, se realizó una búsqueda adicional en el PDB específicamente enfocada en proteínas diseñadas "de novo"publicadas después del 30 de septiembre de 2021. Estas secuencias se sometieron al mismo clasificador de homología para garantizar que no tuvieran similitud con la base de datos pre-2020 y se sumaron al grupo "Novel".

Para garantizar la diversidad estructural y evitar sesgos, se aplicó un filtro estricto de redundancia interna en ambos grupos utilizando alineamiento global “PairWiseAlignment” de la librería de Biopython. El algoritmo comparó todas las secuencias dentro de su respectivo grupo y descartó cualquier proteína que compartiera un 30 % o más de identidad de secuencia con otra proteína previamente aprobada en la misma lista.

A partir de las listas de proteínas completamente únicas y filtradas, se tomaron exactamente 30 proteínas del grupo "Similarz 30 proteínas del grupo "Novel". Estas 60 secuencias maestras (Wild Type o WT) se exportaron a archivos en formato FASTA para ser utilizadas en las posteriores predicciones con AlphaFold2 y ESMFold.

4.2. Creacion del dataset de mutaciones y deleciones

Parte esencial de la metodología del paper original fue la prueba adversaria que se puso sobre AlphaFold y ESMFold, pero no con mutaciones y deleciones al azar, sino que se realizó un esquema biologicamente fundamentado para probar su hipótesis. El objetivo de estos cambios a las secuencias es seguir principios de biofísica y evolución de proteínas para provocar un colapso estructural real y ver si los modelos lo reflejan.

Tanto las mutaciones como las deleciones se realizaron siguiendo un modelo de probabilidad posicional sesgado en el centro de la secuencia. Esto es debido a que en la realidad los extremos de las proteínas suelen ser más flexibles o desordenadas, pero el centro es más estable y más definitivo para la forma y función de la proteína, por lo que alterar el núcleo de manera adeversaria debería desestabilizar la estructura.

Para iniciar el proceso, se importaron los archivos FASTA generados previamente utilizando el módulo “SeqIO” de la librería Biopython, estructurándolos en DataFrames para su procesamiento. Para evitar sesgos en la elección de aminoácidos durante las mutaciones, se implementó un diccionario de sustitución (MUTATION_MAP) extraído directamente de la "Tabla S3” del material complementario del artículo original. Este mapa dicta reglas exactas de reemplazo para cada residuo; por ejemplo, la Serina (S) que es pequeña siempre se muta a Triptófano (W) que es el aminoácido más grande en volumen, y la Asparagina (N) que es polar siempre muta a Alanina (A) que es no polar.

Para dirigir el daño estructural hacia el núcleo de la proteína y evitar afectar únicamente los extremos flexibles, se programó una función de distribución de probabilidad. La probabilidad de que un residuo en la posición i fuera seleccionado para mutación o deleción se calculó utilizando la siguiente fórmula (también adquirida del artículo original)

$$w_i = \epsilon + (1-\epsilon)\left[1 - \frac{|i-(L-1)/2|}{(L-1)/2}\right], \quad i = 0, 1, \ldots, L-1$$

Figura 4: Función de probabilidad posicional usada para mutaciones y deleciones.

Donde L es la longitud de la secuencia y epsilon se fijó en un valor de 0.1. Esta función hace que al momento de mutar o eliminar un aminoácido al azar haya un sesgo de mayor probabilidad para aminoácidos cercanos a la mitad de la secuencia, garantizando que el centro tuviera la mayor probabilidad de ser alterado.

A partir de cada secuencia original (WT), se generaron tres variantes mutadas progresivamente a niveles de 10 %, 40 % y 70 % del total de sus residuos. El algoritmo seleccionó los índices a alterar de forma iterativa y sin reemplazo, basándose en el modelo de probabilidad matemática, y aplicó los cambios según el diccionario predefinido.

De manera independiente a las sustituciones, se crearon tres variantes adicionales por proteína sometidas a eliminación de residuos (deleciones) en proporciones del 3 %, 5 % y 10 %. Los aminoácidos a eliminar fueron seleccionados utilizando el mismo modelo de probabilidad posicional sesgado hacia el centro.

El proceso generó un total de 7 variantes por cada proteína (1 WT, 3 mutaciones y 3 deleciones). Todas las secuencias generadas se guardaron con identificadores estandarizados y se exportaron en archivos consolidados para su posterior evaluación en los modelos predictivos.

4.3. Predicción en AlphaFold

Para la predicción de las estructuras tridimensionales de las 60 secuencias originales y sus respectivas variantes (mutaciones y deleciones), se utilizó la implementación LocalColabFold. Las corridas se realizaron de manera local para optimizar el tiempo de procesamiento, utilizando el modelo de AlphaFold2 por default sin uso de plantillas. Como datos de entrada, se importaron los archivos consolidados en formato FASTA. El hardware empleado consistió en una laptop MSI GE63 RAIDER

RGB 9SE equipada con una GPU NVIDIA GeForce RTX 2060 (6 Gb GDDR6), lo que permitió procesar las variantes de mayor longitud de manera eficiente.

4.4. Predicción en ESMFold

En estas mismas condiciones se ejecutaron las predicciones utilizando ESMFold. Al igual que en el proceso anterior, no se aplicaron procesos de refinamiento posterior para mantener la consistencia en la comparación de ambos modelos. Los resultados obtenidos incluyeron archivos en formato PDB para cada variante, de los cuales se extrajeron los valores de pLDDT (almacenados en la columna del factor B) como métrica de confianza local.

4.5. Procesamiento de resultados de las predicciones para su análisis

Para cuantificar el impacto tridimensional de las modificaciones en la secuencia, cada modelo predicho correspondiente a una variante mutada o delecionada se comparó directamente contra la estructura de su secuencia original no modificada (Wild Type o WT).

Esta comparación se llevó a cabo utilizando TM-align, un algoritmo especializado en la superposición de estructuras de proteínas independiente de la secuencia. TM-align fue seleccionado porque es resistente a las variaciones locales y penaliza menos las regiones desordenadas, ofreciendo una evaluación más robusta del pliegue global.

Mediante un flujo de trabajo automatizado en Python, se procesaron los alineamientos de todas las predicciones (archivos PDB generados previamente) para extraer dos métricas biofísicas fundamentales:

TM-score (Template Modeling Score): Métrica principal utilizada para evaluar la conservación de la topología global. El valor se normalizó respecto a la longitud de la proteína original (WT) para obtener una escala de 0 a 1, donde valores inferiores a 0.5 representan un cambio drástico o colapso en el pliegue tridimensional.

RMSD (Root Mean Square Deviation): Utilizada como métrica secundaria para medir la desviación promedio en las distancias atómicas (en Ångströms) de los carbonos alfa entre ambas estructuras superpuestas.

Los resultados de las comparaciones estructurales se estructuraron en un archivo tabular, catalogando cada variante según su tipo de daño estructural ("Mut"para mutaciones puntuales y "Del"para deleciones) y su magnitud (3 %, 5 %, 10 % para deleciones y 10 %, 40 %, 70 % para mutaciones).

Finalmente, para permitir el análisis comparativo según el tipo de proteína, el algoritmo mapeó los identificadores de cada proteína contra los archivos FASTA de entrada originales.

Esto permitió reasignar a cada fila su clasificación correspondiente ("Novel.º "Similar"), exportando el conjunto de datos definitivo que sirvió como base para los análisis estadísticos de sensibilidad y resistencia estructural.

4.6. Búsqueda y comparación de plantillas con Foldseek

Foldseek es un motor de búsqueda ultra rápido diseñado para comparar estructuras de proteínas: traduce la forma 3D de la proteína a un alfabeto estructural (llamado 3Di), comparando así arquitecturas complejas en milisegundos [11]. Se utilizó en este experimento para verificar si AlphaFold 2 predecía bien las cosas porque realmente modelaba la física, o si simplemente se basaba en estructuras que ya había visto en su base de datos de entrenamiento.

Como paso inicial, se procesaron los resultados directos de las corridas de AlphaFold2 (LocalColabFold). Se implementó un algoritmo en Python para abrir los archivos de coordenadas tridimensionales (PDB) de cada variante y extraer el valor de la métrica de confianza local (pLDDT), la cual se aloja en la columna correspondiente al factor B (B-factor) según el estándar del formato PDB. Estos valores atómicos se promediaron para obtener un nivel de confianza global por proteína.

Para cuantificar la similitud entre las proteínas predichas y las estructuras previamente conocidas, se automatizó una búsqueda exhaustiva utilizando la API del servidor Foldseek. Las 60 estructuras maestras (Wild Type) predichas por AlphaFold2 se consultaron contra la base de datos pdb100. Se especificó explícitamente el uso del modo de alineamiento tmalign para garantizar que la métrica de retorno fuera el qTM-score, permitiendo una evaluación robusta de la topología global independiente de la secuencia.

Puesto que el objetivo era evaluar las plantillas que AlphaFold2 pudo haber utilizado durante su fase de entrenamiento original, se aplicó un estricto filtro cronológico. Por cada coincidencia (hit) estructural encontrada por Foldseek, el script consultó la API pública del Protein Data Bank (RCSB PDB) para extraer la fecha exacta de publicación inicial de dicha estructura. Se descartaron automáticamente todas las estructuras publicadas después de la fecha de corte de entrenamiento de AlphaFold2 (1 de enero de 2020), asegurando que el análisis de similitud se limitara únicamente al conocimiento previo de la IA.

Con las listas de coincidencias filtradas históricamente, se calcularon las medias de similitud estructural (qTM-score) para diferentes niveles de resultados, tales como el mejor hit (Top-1) y los promedios del Top-5, Top-10 y Top-100. Finalmente, se realizó un análisis estadístico utilizando los coeficientes de correlación de Pearson y Spearman para cruzar la confianza de AlphaFold2 (pLDDT) contra el nivel de similitud de la proteína con el PDB pre-2020 (Top-1 qTM-score). Este cruce estadístico permitió determinar matemáticamente si la confianza del modelo estaba significativamente condicionada por la preexistencia de plantillas homólogas.

5. Resultados

5.1. Impacto de mutaciones y deleciones en las predicciones

Los resultados tras comparar las secuencias originales con sus variantes mutadas (Cuadro 1) muestran que AlphaFold 2 suele tener mayor confianza en sus predicciones respecto a su topología real, mostrando una diferencia más marcada para los casos de 70 % de mutaciones, en los que a pesar de tener resultados muy bajos de TM-score su pLDDT era 10 o más puntos más alto (si normalizamos el TM-score de 0 a 100). También hubo casos en los que su TM-score fue un poco mayor que su

pLDDT en los casos de secuencias "similares" con 10 % y 40 % de mutaciones, aunque ESMFold también presentó esta diferencia y más significativamente en el caso del 10 %. En general, ambos modelos tienen peores resultados para las proteínas novel, pero AlphaFold siempre obtiene resultados más altos de confianza que ESMFold, independientemente del tipo de proteína y el porcentaje de mutaciones.

Cuadro 1: Resultados agregados para mutaciones.

Tipo	Mutación (%)	N Casos	AF2 TM Prom	AF2 pLDDT	AF2 Brecha	ESM TM Prom	ESM pLDDT	ESM Brecha
Novel	10	29	0.80	79.49	-0.00	0.67	61.81	-0.05
Novel	40	29	0.52	56.08	0.04	0.31	39.71	0.09
Novel	70	29	0.31	48.78	0.18	0.29	35.11	0.06
Similar	10	28	0.93	86.25	-0.06	0.86	76.39	-0.10
Similar	40	28	0.61	55.13	-0.06	0.40	33.68	-0.06
Similar	70	28	0.26	36.54	0.11	0.25	28.32	0.03

En la Figura 5 se muestra en el eje x los tres porcentajes de mutación que se utilizó para las secuencias mientras que el eje y muestra el promedio general de TM-score. La línea punteada indica la altura correspondiente al TM-score de 0.5. Se puede apreciar que que AlphaFold 2 mantiene un TM-score mayor a 0.5 incluso para 40 % de mutaciones, caso en el que ESMFold cae más bruscamente. En general AlphaFold siempre tiene mayor TM-score que ESMFold. Los diagramas de violín de la Figura 6 nos muestran además que ESMFold suele dar resultados más específicos y congruentes entre sí, mientras que para AlphaFold hay más dispersión del TM-score, sobre todo para el caso de 40 % de mutaciones.

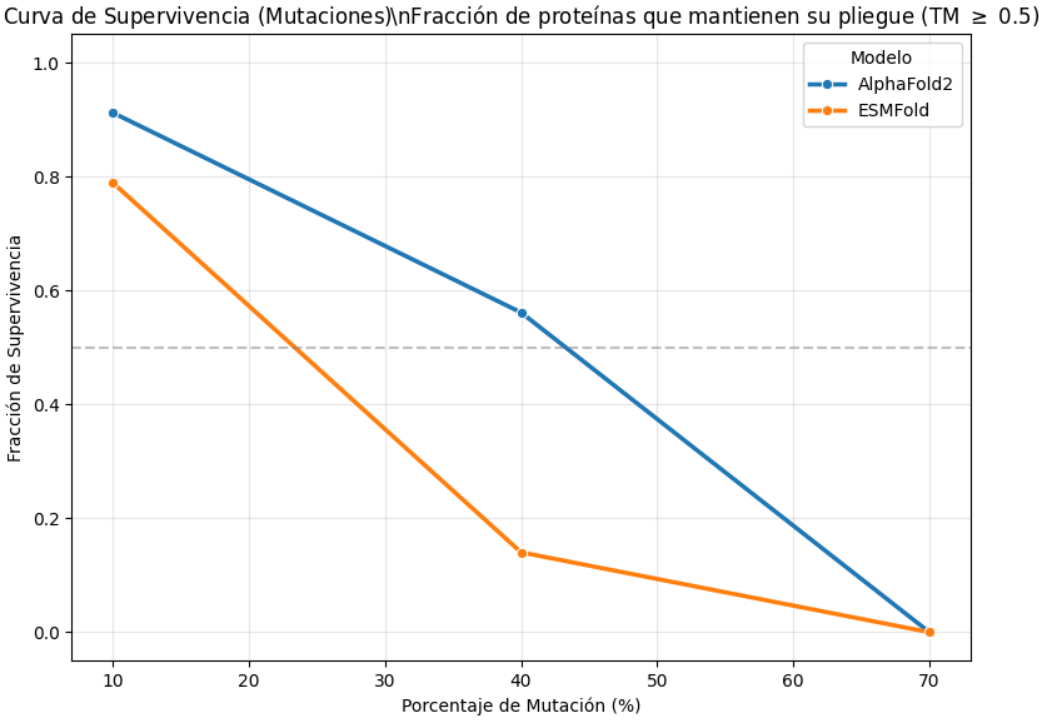

Figura 5: Comparación de TM-score bajo mutaciones.

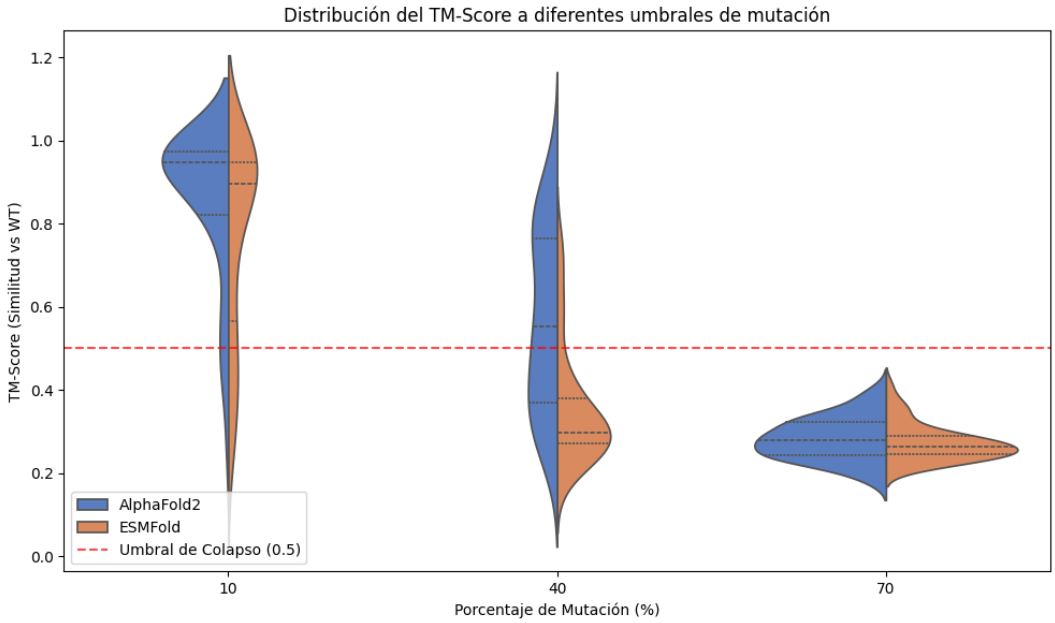

Figura 6: Comparación de TM-score bajo mutaciones.

Por otro lado para las deleciones también se mostró en general una mayor confianza de AlphaFold 2 sobre su topología real y en comparación con la confianza de ESMFold, sin embargo algo curioso fue que en el caso de proteínas similares ambos modelos presentaron un TM-score mayor a su pLDDT.

Cuadro 2: Resultados agregados para deleciones.

Tipo	Deleción (%)	N Casos	AF2 TM Prom	AF2 pLDDT	AF2 Brecha	ESM TM Prom	ESM pLDDT	ESM Brecha
Novel	3	29	0.75	76.18	0.01	0.65	63.09	-0.02
Novel	5	29	0.65	71.67	0.07	0.58	58.80	0.00
Novel	10	29	0.52	63.81	0.12	0.47	52.62	0.06
Similar	3	28	0.88	84.40	-0.04	0.85	74.91	-0.10
Similar	5	28	0.83	80.02	-0.03	0.80	70.65	-0.09
Similar	10	28	0.71	69.66	-0.01	0.67	56.12	-0.11

Las gráficas en la Figura 7 y Figura 8 muestran que para el caso de deleciones ESMFold tiene un comportamiento más parecido al de AlphaFold 2. Además ambos modelos presentan puntuaciones de TM mayores de 0.5 para la mayoría de sus proteínas en los tres niveles de deleción.

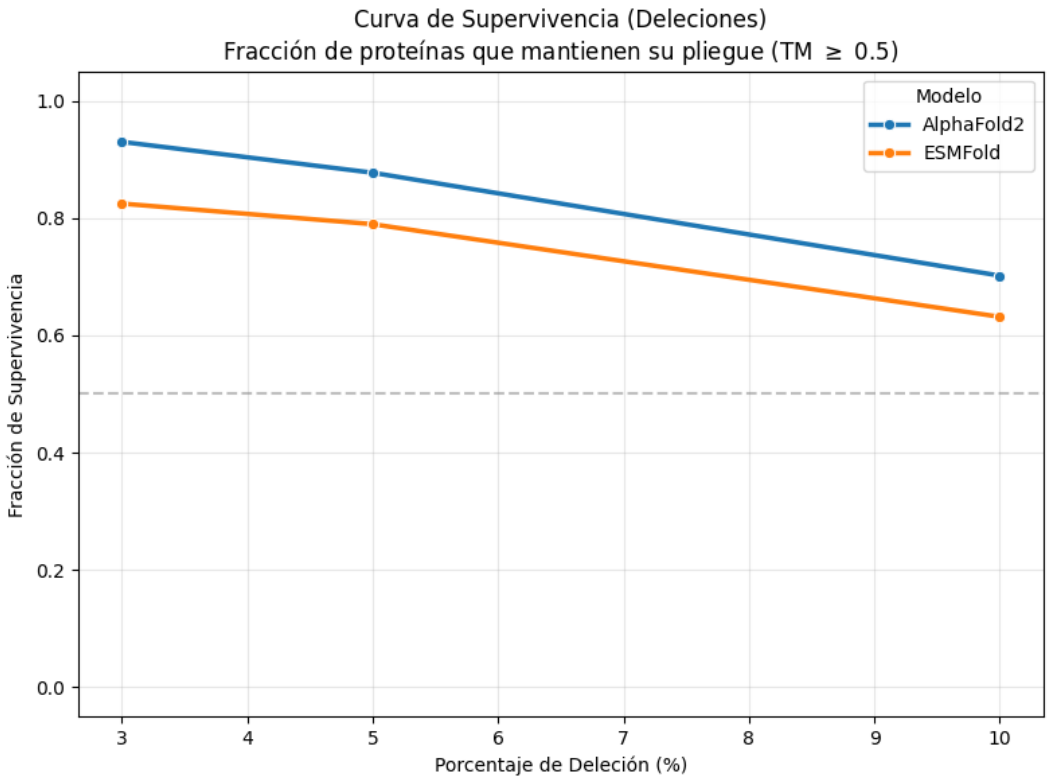

Figura 7: Comparación de TM-score y pLDDT bajo deleciones.

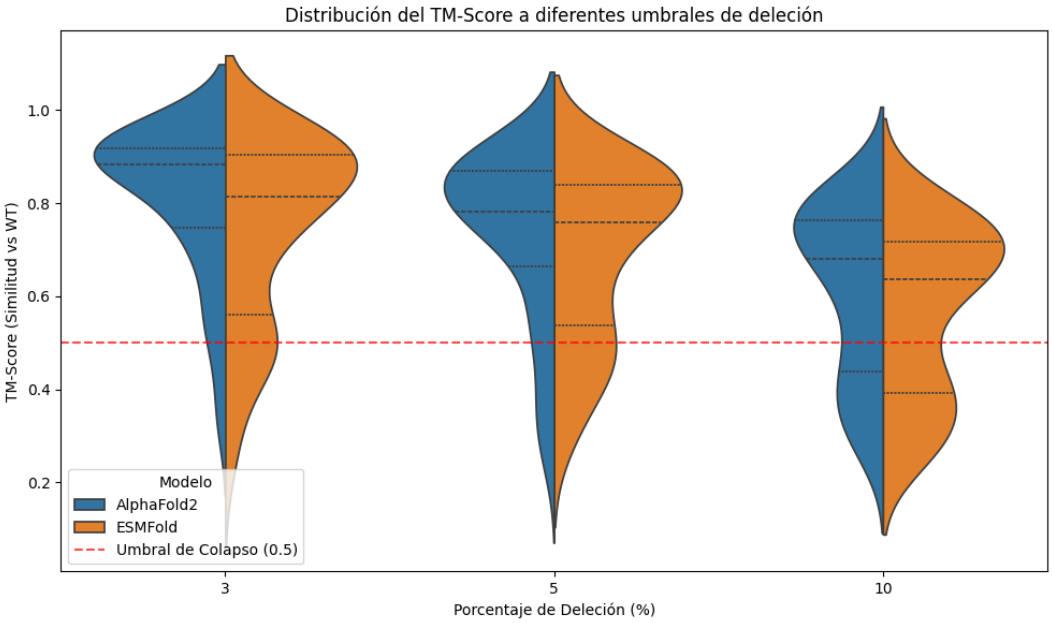

Figura 8: Comparación de TM-score y pLDDT bajo deleciones.

En el cuadro 3 se muestran algunos de los casos en los que las proteínas predichas por AlphaFold

tuvieron niveles muy altos de TM-score y pLDDT, a pesar de haber sufrido varios porcentajes de mutación y deleción.

Cuadro 3: Ejemplos de predicciones con TM-score y pLDDT altos.

Proteina	Variante_Completa	TM_Score_AF	pLDDT_AF
6L5H	Mut_10	0.99209	97.27
9TAV	Mut_40	0.97354	80.74
20XX	Del_3	0.95657	86.07
10PW	Del_5	0.92069	88.1
5QKC	Del_10	0.84503	77.08

5.2. Comparación de predicción y plantillas con Foldseek

Los resultados de la búsqueda de plantillas en Foldseek (Cuadro 4) reveló que la semejanza de las predicciones de AlphaFold con las estructuras conocidas del Protein Data Bank es menor para proteínas "novel" que para las "similares". También se puede observar que dicho puntaje va bajando conforme se toman más "hits", aunque para esos promedios hay una variabilidad entre la cantidad de hits para cada proteína, habiendo proteínas con solo 4 hits hasta otras con 673 hits.

Cuadro 4: Resumen de coincidencias estructurales obtenidas con Foldseek.

Origen Evolutivo	N_Proteinas	Hits_Totales_Prom	Hits_Pre2020_Prom	Top1_TM_Prom	Top1_TM_Rango	Top10_TM_Prom	Top100_TM_Prom
Novel	29	254.83	184.66	0.60	0.00 - 0.91	0.55	0.49
Similar	29	365.76	263.97	0.88	0.56 - 0.98	0.82	0.68

Con la biblioteca scipy.stats se calcularon los coeficientes de correlación de Pearson y Spearman para el primer resultado regresado por Foldseek contra el promedio de los 100 primeros resultados (Cuadro 5). Para el caso de la primera estructura se obtuvo un valor mayor a 0.6 para ambos coeficientes y un p-value mucho menor a 0.05, lo que indica una alta correlación entre la plantilla más parecida y la predicción de AlphaFold (Figura 9). Este coeficiente sin embargo baja hasta menos de 0.5 cuando se toman las primeras 100 plantillas y también el p-value aumenta (Figura 10).

Cuadro 5: Correlaciones entre similitud de plantillas y robustez.

	Top1 TM	Top 100 TM
Coeficiente de Pearson	0.6188	0.4762
P-value (Pearson)	2.2482e-7	1.5803e-4
Coeficiente de Spearman	0.6559	0.4220
P-value (Spearman)	2.2908e-7	9.6881e-4

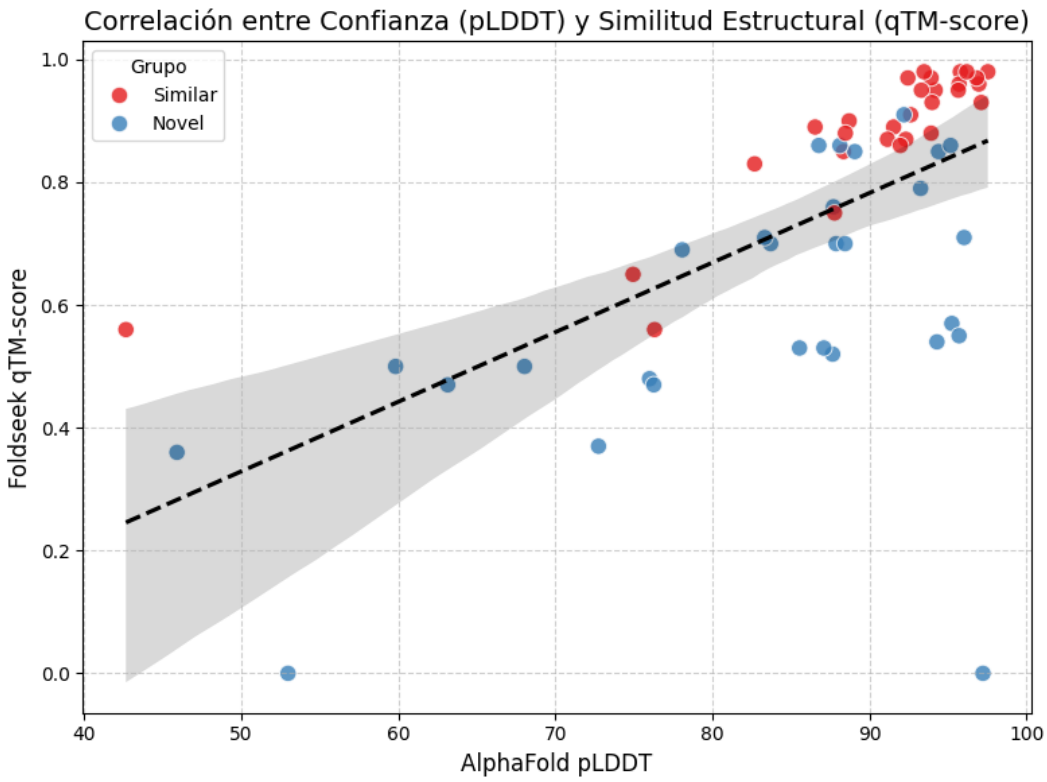

Figura 9: Correlación entre las predicciones y su mejor plantilla.

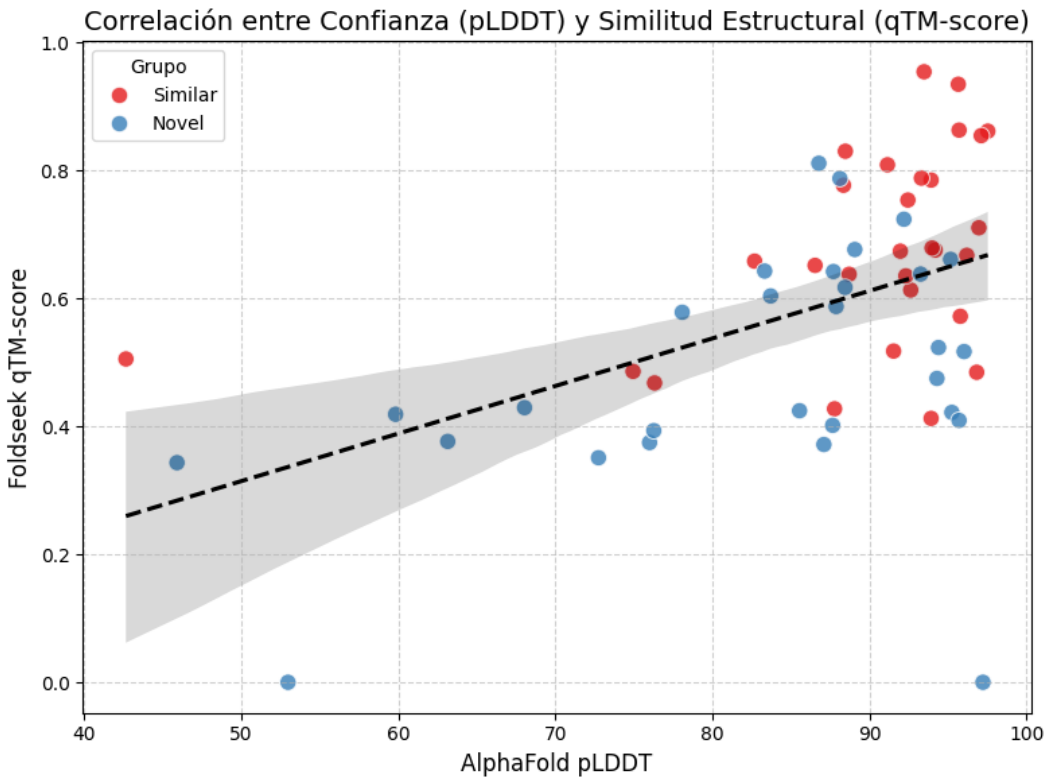

Figura 10: Correlación entre las predicciones y sus mejores 100 plantillas.

6. Discusión

6.1. Interpretación de los resultados

Se ha encontrado que la confianza de AlphaFold sí disminuye progresivamente de manera similar a la disminución del TM-score, aunque hay algunos casos en los que, a pesar de tener fuertes niveles de mutación y deleción, su predicción no es muy diferente de la de la proteína de tipo silvestre (wild type), y su confianza se mantiene relativamente alta. Basándonos en los fines adversarios biofísicos que tuvieron estas modificaciones, al recibir estos niveles de cambio la estructura de las secuencias variantes deberían ser muy diferentes a la original sin mutar. El hecho de que haya casos en los que la estructura se mantenga parecida puede indicar que AlphaFold no usa una base sólida de las propiedades biofísicas de las secuencias. Otro patrón encontrado es que para las proteínas "similares", que comparten homología con PDB antes del "corte de entrenamiento" para AlphaFold 2, presentaron valores de TM-score mayores que las "novel" (con menos de 30 % de homología con proteínas publicadas antes de 2020). Esto podría indicar que sí hay información del entrenamiento que AlphaFold 2 está memorizando y utilizando para realizar las predicciones cuando puede, incluso cuando se especifica que no se utilicen plantillas para la predicción.

Al compararlo con ESMFold, este último mantuvo menores valores de confianza que AlphaFold y también sus TM-score de secuencias mutantes fueron más bajas que las de AF al compararlas con

predicciones sin modificaciones. Para el caso de mutaciones, específicamente, ESMFold demostró ser más sensible a los cambios y su TM-score caía como se esperaría. Esto indica que ESMFold sigue lineamientos biofísicos en su modelación del lenguaje de aminoácidos y secuencias de polímeros. Sin embargo, para el caso de deleciones, si bien ESMFold también tuvo menores valores de TM-score, estos no fueron significativamente diferentes a los de AlphaFold como en el caso de mutaciones. Esto indicaría que para los casos de mutación, ESMFold es capaz de detectar las diferencias estructurales pero si se eliminan fragmentos de la secuencia comienza también a utilizar cosas aprendidas en el entrenamiento que lo llevan a generar estructuras similares a la original.

Los resultados de Foldseek mostraron que sí hay una correlación entre la disponibilidad y calidad de las plantillas, y la confianza que tiene el modelo al predecir. Por un lado esto podría indicar que AlphaFold sí memorizó patrones de las plantillas con las que fue entrenada y este overfitting afecta sus predicciones llevándolas a adaptarse a cosas conocidas. Otra interpretación de este resultado podría ser que la salida de AlphaFold sea independiente de las plantillas y que haya menos plantillas disponibles para las proteínas "novel" porque son más recientes y algunas son de novo; además, puede existir un factor temporal en las estructuras que la comunidad científica conoce y genera.

Al comparar los resultados de ambos experimentos, sí se puede notar que hay algún tipo de conocimiento de entrenamiento que le permite a AlphaFold ser mejor para las proteínas similares que para las novel, esto sí podría estar relacionado a las plantillas, como se observó con Foldseek, pero también hay información fuera de las plantillas que pudo haber sido aprendida, como se vio en el caso de ESMFold con las deleciones.

Se requieren metodologías más específicas que permitan determinar cosas que aún permanecen ambiguas en este problema. Además de la ejecución con una mayor cantidad de datos se puede realizar un análisis más exhaustivo con otras métricas de confianza de las predicciones y calificación de las estructuras, incluyendo también las similitudes con plantillas y estructuras predichas experimentalmente.

7. Conclusiones

Ambos modelos muestran evidencia de uso de patrones aprendidos, aunque para AlphaFold esto fue más claro, sobre todo en el caso de proteínas mutadas, donde ESMFold pareció ser más sensible y tuvo un comportamiento más consistente con los principios biofísicos. Es necesario seguir desafiando y cuestionando los resultados de esta clase de modelos. Al ser muy utilizados en diferentes campos de las ciencias de la vida se debe tener claridad de cuando se pueden usar o no estos modelos. Por ejemplo para los casos de proteínas diseñadas o mutadas, podría ser más conveniente usar ESMFold sobre AlphaFold, en congruencia con los resultados obtenidos en este proyecto.

Hace falta una investigación más rigurosa para entender bien cuáles son exactamente esos patrones y si están relacionados con las plantillas utilizadas para el entrenamiento de AlphaFold.

Es verdad que AlphaFold ha revolucionado la biología estructural y es una herramienta muy poderosa para quienes se dedican a campos relacionados con la biología celular y molecular, pero se debe tener claro que tiene limitaciones respecto a su comprensión de propiedades biofísicas y muestra un leve y ambiguo sobreajuste.

8. Referencias

1. Jumper, J., Evans, R., Pritzel, A., Green, T., Figurnov, M., Ronneberger, O., Tunyasuvunakool, K., Bates, R., Žídek, A., Potapenko, A., Bridgland, A., Meyer, C., Kohl, S. A. A., Ballard, A. J., Cowie, A., Romera-Paredes, B., Nikolov, S., Jain, R., Adler, J., . . . Hassabis, D. (2021b). Highly accurate protein structure prediction with AlphaFold. Nature, 596(7873), 583-589.

2. Callaway, E. (2020). 'It will change everything': DeepMind's AI makes gigantic leap in solving protein structures. Nature, 588(7837), 203-204.

3. Bertoline, L. M. F., Lima, A. N., Krieger, J. E., & Teixeira, S. K. (2023b). Before and after AlphaFold2: An overview of protein structure prediction. Frontiers In Bioinformatics, 3, 1120370.

4. Varadi, M., & Velankar, S. (2022). The impact of AlphaFold Protein Structure Database on the fields of life sciences. PROTEOMICS, 23(17), e2200128.

5. Pak, M. A., Markhieva, K. A., Novikova, M. S., Petrov, D. S., Vorobyev, I. S., Maksimova, E. S., Kondrashov, F. A., & Ivankov, D. N. (2023). Using AlphaFold to predict the impact of single mutations on protein stability and function. PLoS ONE, 18(3), e0282689.

6. Feldman, J., Brogi, M., & Skolnick, J. (2026). Adversarial Sequence Mutations in AlphaFold and ESMFold Reveal Nonphysical Structural Invariance, Confidence Failures, and Concerns for Protein Design. bioRxiv (Cold Spring Harbor Laboratory).

7. Rubiera, C. O. (2021, 19 julio). AlphaFold 2 is here: what's behind the structure prediction miracle | Oxford Protein Informatics Group.

8. Lin, Z., Akin, H., Rao, R., Hie, B., Zhu, Z., Lu, W., Smetanin, N., Verkuil, R., Kabeli, O., Shmueli, Y., Costa, A. D. S., Fazel-Zarandi, M., Sercu, T., Candido, S., & Rives, A. (2023). Evolutionary-scale prediction of atomic-level protein structure with a language model. Science, 379(6637), 1123-1130.

9. Embl-Ebi. (s. f.). pLDDT: Understanding local confidence | AlphaFold.

10. Depner, L. (2017, 4 enero). TM-Score | Oxford Protein Informatics Group.

11. Van Kempen, M., Kim, S. S., Tumescheit, C., Mirdita, M., Lee, J., Gilchrist, C. L. M., Söding, J., & Steinegger, M. (2023). Fast and accurate protein structure search with Foldseek. Nature Biotechnology, 42(2), 243-246.